

机器学习笔记

starAndHonor 未来技术学院

日期: 25,Fall

目录

决策树	8
熵	9
条件熵	10
信息增益	11
估计	12
最大似然估计(MLE)	13
MLE 计算技巧	14
最大后验估计(MAP)	15
最大条件概率估计	16
朴素贝叶斯算法	17
原理	18
典型朴素贝叶斯(特征是离散/类别型)	20
高斯贝叶斯分布	21
线性回归模型	22
线性模型	23

均方误差	24
最小二乘估计(高数方法)	25
先验估计	26
后验估计	27
梯度下降法	28
三种梯度下降方法	29
学习率选择	30
优缺点	31
逻辑回归	32
问题	33
几率和对数几率	34
sigmoid 函数	35
统计学解释	36
推广:多种类别情况	37
MCLE	38
MAP	39
生成式和判别式分类器	40
非线性变换	41
逻辑回归的训练	42

机器理论	43
PAC 理论	44
shatter	45
shatter 的几个例子	46
VC 维	47
有效假设数量	48
关于 $H[m]$ 的例子	49
增长函数	50
VC 维的例子	51
无限 H 情况下的 PAC	53
SRM(Structural Risk Minimization)	54
图模型	55
贝叶斯网络	56
因子分解 factorization	57
构造贝叶斯网络	58
贝叶斯网络学习	59
推理贝叶斯网络	60
D-separated	61
马尔可夫毯	62

.....	63
时间序列和马尔可夫模型	64
状态空间模型	65
集成学习	66
adaboost	67
kmeans	68
kmeans 算法	69
参数 k 和起始中心点的选择	70
起始中心点的选择	70
参数 k	70
异常检测	71
高斯异常检测	72
联合高斯分布	73
SVM	74
目标	75
损失函数和梯度下降	76
预测	77
核方法	78
核方法	79

常见的核函数	80
核 svm	81
关于高斯核参数	82
神经网络	83
前向传播	84
损失函数	85
反向传播	86
实现技巧	87
online learning	88
online learning	89
online svm	90
半监督学习	91
概念	92
co-training	93
推荐系统	94
问题和目标	95
已知内容的推荐系统	96
协同过滤算法	97
低秩矩阵分解	98

寻找相似电影	99
均值归一化	100
训练数据	101
大量数据和人工合成	102
调试机器学习	103
评估模型	104
模型调试	105
评估指标	107
TP,FP,FN,TN,Precision,Recall,F1	108
F1-Score	109

决策树

熵

熵（Entropy）是信息论中的概念，用来度量随机变量的混乱程度。熵越小，则信息越少，则混乱程度越小。熵越大，则信息越多，则混乱程度越大

$$H(Y) = - \sum p(y_i) \times \log_2 p(y_i)$$

条件熵

条件熵（Conditional Entropy）是信息论中的概念，用来度量随机变量的混乱程度。

$$H(Y|X) = - \sum \left(p(x_i) * \sum p(y_i|x_i) \times \log_2(p(y_i|x_i)) \right)$$

信息增益

信息增益 (Information Gain) 是信息论中的概念, 用来度量信息量的变化。

$$G(X, Y) = H(Y) - H(Y|X)$$

在决策树建树的过程中, 选取信息增益最大的特征作为根节点, 然后根据该特征对数据集进行划分, 并继续递归地构建子树。

估计

最大似然估计(MLE)

假设观测到的数据是 $x_1, x_2, \dots, x_n$.他们相互独立

目标是估计一个 θ ,使得数据出现的可能性(似然) $p(\boldsymbol{x}|\theta)$ 最大,即

假设似然函数为

$$L(\theta) = \prod_{i=1}^n p(x_i|\theta)$$

求

$$\operatorname{argmax}_{\theta} L(\theta)$$

MLE 计算技巧

1. 假设似然函数

$$L(\theta) = \prod_{i=1}^n p(x_i|\theta)$$

2. 取对数

$$\ln L(\theta) = \sum_{i=1}^n \ln p(x_i|\theta)$$

3. 令偏导为 0

$$\frac{\partial \ln L(\theta)}{\partial \theta} = 0$$

4. 求解偏导为 0 的方程,得到 $\hat{\theta}_{\text{MLE}}$

最大后验估计(MAP)

贝叶斯估计:

$$p(\theta|\boldsymbol{x}) = \frac{\overbrace{p(\boldsymbol{x}|\theta)}^{\text{似然}} \times \overbrace{\pi(\theta)}^{\text{先验概率}}}{p(\boldsymbol{x})}$$

参数 θ 是一个随机变量,服从某种先验分布,表示我们观测数据前对参数的**信念**.
通过贝叶斯公式,使用观测数据 $\boldsymbol{X}$ 给出的信息**更新**了我们对参数 θ 的信念.

最大后验估计就是

$$\operatorname{argmax}_{\theta} P(\theta|\boldsymbol{x}) = \operatorname{argmax}_{\theta} (P(\boldsymbol{x}|\theta) \times \pi(\theta))$$

同样取对数,计算.

最大条件概率估计

目标是估计一个 θ 使得最大化在条件 C 下发生 X 的概率 $P(X|\theta, C)$

朴素贝叶斯算法

原理

模型的目标是完成分类任务.要估计的参数为类别 θ

此时可以认为贝叶斯公式是

$$p(\theta|\mathbf{x}) = \frac{\overbrace{p(\text{特征向量}|\text{类别})}^{\text{似然}} \times \overbrace{\pi(\text{类别})}^{\text{先验概率}}}{p(\text{特征向量})}$$

分类依据: 根据贝叶斯公式, 选择最大后验概率的参数作为估计结果
 $\operatorname{argmax}_{\theta} P(\theta | \mathbf{x}) \times \pi(\theta)$

核心假设: 特征 $x_1, x_2, \dots, x_n$ 是条件独立的. 既

$$p(x_1, x_2, \dots, x_n | \theta) = p(x_1 | \theta) \times p(x_2 | \theta) \times \dots \times p(x_n | \theta)$$

原理

$$p(\theta|\mathbf{x}) \propto \overbrace{\prod p(\text{特征}_i|\text{类别})}^{\text{似然}} \times \overbrace{\pi(\text{类别})}^{\text{先验概率}}$$

分母对于同一个特征向量的所有式子都是一样的,用于归一化,可以不管
目标转化为估计概率 $p(\text{特征}_i|\text{类别})$ 和 $\pi(\text{类别})$

这两个概率都可以通过训练集进行估计.

估计 $\pi(\text{类别})$ 可以使用 MLE:

$$\pi(\text{类别}) = \frac{N_c}{N}$$

或者 MAP,考虑分布的先验.

典型朴素贝叶斯(特征是离散/类别型)

MLE:

$$p(\text{特征}_i | \text{类别}_c) = \frac{N_{c,i}}{N_c}$$

问题: 如果数据少,可能会出现存在 $p(\text{特征}_k | \text{类别}_c) = 0$,导致数据中存在特征 k 的时候似然为 0,导致一票否决,引入 laplace 平滑,其相当于下面的 MAP

MAP:

如果特征是词计数:服从多项分布,使用 Dirichlet($\alpha, \alpha, \dots, \alpha$)先验

$$p(\text{特征}_i | \text{类别}_c) = \frac{N_{c,i} + \alpha}{N_c + \alpha N_d}$$

如果特征是(0/1):服从二项分布,使用 beta 先验(二维情况下 Dirichlet),所以 $N_d = 2$

高斯贝叶斯分布

问题:上面讲的概率分布都是离散的,如果特征是连续的,应该怎么估计概率 $p(\text{特征}_i | \text{类别}_c)$?

假定在给定类别 c 的情况下,特征 i 的概率分布为高斯分布:

$$p(\text{特征}_i | \text{类别}_c) = \frac{1}{\sqrt{2\pi}\sigma_{i,c}} \exp\left(-\frac{(x - \mu_{i,c})^2}{2\sigma^2}\right)$$

所以只需要统计类别 c 下特征 c 的 $\sigma_{i,c}$ 和 $\mu_{i,c}$, 就可以计算.

线性回归模型

线性模型

线性模型试图学得一个通过属性的线性组合来进行预测的函数。

$$f(x) = w_1x_1 + w_2x_2 + \dots + w_nx_n + b$$

向量形式为 $f(x) = w^T x + b$

线性回归模型: $f(x) = w^T x + b$ 使得 $f(x_i) \approx y_i$

善于处理数值属性，需要将离散属转换为连续属性。

需要考虑**顺序**(order)。

- 有序: 直接连续化
- 无序: onehot 转化为 k 维向量

均方误差

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (f(x_i) - y_i)^2$$

均方误差衡量了模型预测与真实结果之间的平均平方偏差。

特征如下：

1. 所有误差为正
2. 大误差被更严重地惩罚

最小二乘估计(高数方法)

我们的目标是使均方误差最小化

将原函数记为 $y = Xw$

$$\text{MSE} = \frac{1}{2} \|Xw - y\|^2 = \frac{1}{2}(y - Xw)^T(y - Xw) = y^T y - 2w^T X^T y + w^T X^T X w$$

求 $\text{agrmin}_w \text{MSE}$

$$\frac{\partial(\text{MSE})}{\partial(w)} = -2X^T y + 2X^T X w = 0 \text{ 解得}$$

$$w = (X^T X)^{-1} X^T y$$

先验估计

假设 $y = f(x) + \varepsilon, \varepsilon \sim N(0, \sigma^2)$ 那么 $f(x) \sim N(x^T w, \sigma^2)$

似然函数为

$$L(w) = \prod_{i=1}^d \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(f(x) - x^T w)^2}{2\sigma^2}\right)$$

取对数

$$\ln(L(w)) = \sum_{i=1}^d -\log(\sqrt{2\pi}\sigma) - \frac{(f(x) - x^T w)^2}{2\sigma^2}$$

求 $\operatorname{argmax}_w \ln(L(w))$ 可以认为是求 $\operatorname{argmin}_\theta \sum_{i=1}^d (f(x) - x^T w)^2$

这解释了为什么 “MSE” 可以作为损失函数.(MLE 估计下的损失函数)

后验估计

给权重 w 一个先验假设

$$w \sim N(0, \tau^2 I)$$

那么

$$\begin{aligned} P(w | x) &= P(x | w) \times P(w) \\ &= \prod_{i=1}^d \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(f(x) - x^T w)^2}{2\sigma^2}\right) \times \prod_{i=1}^d \frac{1}{\sqrt{2\pi}\tau} \exp\left(-\frac{w^2}{2\tau^2}\right) \end{aligned}$$

取对数并求导有: $\operatorname{argmax}_w -\frac{(f(x)-x^T w)^2}{2\sigma^2} - \frac{w^2}{2\tau^2}$

相当于 $\operatorname{argmin}_w \frac{1}{2}(f(x) - x^T w)^2 + \frac{\sigma^2}{2\tau^2} w^2$ 令 $\lambda = \frac{\sigma^2}{2\tau^2}$,

则 $\operatorname{argmin}_w \frac{1}{2}(f(x) - x^T w)^2 + \lambda w^2$, w^2 为 L_2 正则项, 可以防止过拟合.


梯度下降法

我们的目标是最小化 loss 函数.

$$w_{i+1} = w_i - \eta \nabla \text{Loss}(w_i)$$

梯度的含义是: 函数在当前点增大最快的方向.反方向就是在当前点下降最快的

方向.



三种梯度下降方法

1. **随机梯度下降**:每次有放回选取一个样本 j ,计算梯度, 并更新参数

$$w_{i+1} = w_i - \eta \nabla \text{Loss}_j(w_i)$$


2. **批量梯度下降**:使用所有的 m 个样本计算梯度, 并更新参数

$$w_{i+1} = w_i - \eta \frac{1}{m} \sum_{j=1}^m \nabla \text{Loss}_j(w_i)$$

3. **小批量随机梯度下降**:选取一个批量为 b 的批量 batch 进行梯度下降

$$w_{i+1} = w_i - \eta \frac{1}{b} \sum_{j=1}^b \nabla \text{Loss}_j(w_i)$$

学习率选择



大坡用小步，小坡用大步 → 刚刚好

优缺点

方法	随机梯度下降	批量梯度下降	下批量随机梯度下降
优点	收敛方向稳定，速度快。	梯度精确,适合大数据集	速度快，稳定性比SGD 好
缺点	梯度噪声大，收敛不稳定	计算量大,速度较慢	需要选择合适的batch size

逻辑回归

问题

- 输入特征为 $x_1, \dots, x_n$,
- 标签 Y 为 $\{0, 1\}$
- $P(X_j | Y = y_i)$ 满足高斯分布 $N(\mu_{j,i}, \sigma_{j,i})$
- $P(Y)$ 满足伯努利分布

如何使用直接估计 $P(y|X)$ 的方式分类?

几率和对数几率

motivation: 线性回归模型预测出来的结果在 $(-\infty, \infty)$,但是我们需要的预测结果是在 $\{0, 1\}$,需要有一种映射关系.

几率 odds,表示的是正事件发生的概率和负事件发生的概率之比.

$$\text{odds} = \frac{p}{1-p}$$

对数几率(logit 函数)

$$\text{logit}(p) = \log\left(\frac{p}{1-p}\right)$$

可以发现 $\begin{cases} \text{logit}(p) > 0 & p > 0.5 \\ \text{logit}(p) = 0 & p = 0.5 \\ \text{logit}(p) < 0 & p < 0.5 \end{cases}$

我们不直接估计概率,而是去估计对数几率, p 为 $P(y = 1 | x)$.即


$$x^T w = \log\left(\frac{p(x)}{1-p(x)}\right)$$

sigmoid 函数

由此可以推出

$$f(x) = \frac{1}{1 + e^{-x^T w}}$$

其图像如下



统计学解释

假设 $N(\mu_{j,i}, \sigma_{j,i})$ 中的 $\sigma_{j,i} = \sigma_i$

$$P(y = 1 \mid x) = \frac{P(x|y = 1) \times P(y = 1)}{P(x|y = 1) \times P(y = 1) + P(x|y = 0) \times P(y = 0)}$$

$$= \frac{1}{1 + \frac{P(x|y=0) \times P(y=0)}{P(x|y=1) \times P(y=1)}}$$

$$= \frac{1}{1 + e^{\ln \frac{P(x|y=0) \times P(y=0)}{P(x|y=1) \times P(y=1)}}}$$

$$= \frac{1}{1 + e^{\ln \frac{1-\pi}{\pi} + \sum_i \left(\frac{\mu_{0,i} - \mu_{1,i}}{\sigma^2} x_i - \frac{\mu_{0,i}^2 - \mu_{1,i}^2}{2\sigma^2} \right)}}$$

令 $w_0 = \ln \frac{1-\pi}{\pi} - \frac{\sum_i (\mu_{0,i}^2 - \mu_{1,i}^2)}{2\sigma^2}$, $w_i = \sum_i \frac{\mu_{0,i} - \mu_{1,i}}{\sigma^2} x_i$ 有

$$f(x) = \frac{1}{1 + e^{-x^T w}}$$

推广:多种类别情况

多类逻辑回归用 softmax 把 R 个线性得分变成概率分布, 并通过固定其中一类的权重为 0, 只需估计 $R-1$ 组权重即可。

使用 softmax, 假设 $y \in \{c_1, c_2 \dots c_R\}$

对于 $i < R$

$$P(y = c_i \mid x) = \frac{e^{-x^T w_i}}{1 + \sum_{j=1}^R e^{-x^T w_j}}$$

对于 $i = R$

$$P(y = c_i \mid x) = \frac{1}{1 + \sum_{j=1}^R e^{-x^T w_j}}$$

softmax 模型冗余: 同时给所有 w_i 加上同一个常数向量, 概率不变。因为相当于上下同时乘上 e 的若干次. 所以设定 $w_R = (0, 0, 0, \dots, 0)$

MCLE

$P(y \mid x)$ 服从伯努利分布

$$P(y \mid x, w) = p^y(1 - p)^{1-y}$$

其中 $p = \hat{y} = \frac{1}{1+e^{-w^T x}}$

似然函数为

$$L(w) = \prod_{i=1}^m p^y(1 - p)^{1-y}$$

取对数

$$\operatorname{argmax}_w \log L(w) = \operatorname{argmax}_w \sum_{i=1}^m y \log \hat{y} + (1 - y) \log(1 - \hat{y})$$

$$\operatorname{argmax}_w \log L(w) = \operatorname{argmin}_w (-\log L(w)) = \operatorname{argmin}_w \left(-\sum_{i=1}^m (y \log \hat{y} + (1 - y) \log(1 - \hat{y})) \right)$$

括号内的式子称为交叉熵(cross entropy)

MAP

假设给权重 w 一个先验假设

$$w \sim N(0, \tau^2 I)$$

$$P(w, y \mid x) = \frac{1}{\sqrt{2\pi\tau}} \exp^{-\frac{w^2}{2\tau^2}} \times P(y \mid x, w)$$

取对数并乘上 $2\sigma^2$,并整体取负,后相当于增加了一项正则项 $w^2 \frac{\sigma^2}{\tau^2}$,即 $\frac{\sigma^2}{\tau^2} = \lambda$,与线性回归中的正则项类似

生成式和判别式分类器

生成式分类器: 通过 $P(x|y)$ 和 $P(x)$ 计算 $P(y|x)$ 的概率,比如贝叶斯分类.

判别式分类器: 直接计算 $P(y|x)$,比如逻辑回归.

Bias: 模型为了简化问题而产生的系统性误差

Variance: 模型对于训练数据集的敏感程度

Bayes:

- 假设给定类别的时候,各个特征分布独立,是一个强条件
- 少数据效果更好,因为参数量少更加简单

总结: Bias 大, Variance 小

逻辑回归:

- 假定对数几率符合正态分布,比独立要弱一些
- 需要大量参数克服噪声的影响

总结: Bias 小, Variance 大

需要 Bias-Variance trade-off

非线性变换

Why: 我们现在的模型只能建模线性关系,但是现实中大多是非线性关系.

What: 使用一个函数将 x 映射到另一个空间中,如 $(x_1, x_2, x_3) \rightarrow (x_1^2, x_1x_2, x_1x_3, x_2^2, x_2x_3, x_3^2)$

好处: 模型更加复杂,可以建模更多的关系

代价: 计算量增加,复杂度增加,同时 VC 维度低于变换后的特征数目+1

逻辑回归的训练

交叉熵的梯度

假如 $y \in \{0, 1\}$,

对于一个样本 $x^{(i)}$

$$\begin{aligned}
 \nabla L &= \frac{\partial(-y^{(i)} \log \hat{y}^{(i)} - (1-y^{(i)}) \log(1-\hat{y}^{(i)}))}{\partial w} \\
 &= \frac{\partial\left(-y^{(i)} \log \frac{1}{1+e^{-w^T x}} - (1-y^{(i)}) \log\left(1 - \frac{1}{1+e^{-w^T x}}\right)\right)}{\partial w} \\
 &= \frac{\partial\left(y^{(i)} \log\left(1+e^{-w^T x}\right) + (1-y^{(i)})\left(w^T x + \log\left(1+e^{-w^T x}\right)\right)\right)}{\partial w} \\
 &= \frac{\partial\left(\log\left(1+e^{-w^T x}\right) + w^T x - y^{(i)} w^T x\right)}{\partial w} \\
 &= \frac{-x e^{-w^T x}}{1+e^{-w^T x}} + x - y^{(i)} x \\
 &= x\left(\hat{y}^{(i)} - 1 + 1 - y^{(i)}\right) \\
 &= \left(\hat{y}^{(i)} - y^{(i)}\right) x^{(i)}
 \end{aligned}$$

梯度下降公式为 $w_{i+1} = w_i - \eta \frac{1}{m} \sum (\hat{y}^{(i)} - y^{(i)}) x^{(i)}$

机器理论

PAC 理论

$$\Pr_{x \sim D}[h(x) \neq c^*(x) \leq \varepsilon] \geq 1 - \delta$$

Realizable PAC: 在目标函数 $c^*(x) \in H$ 时候需要的数据量 m 为

$$m = \frac{1}{\varepsilon} \times \left(\log|H| + \log\left(\frac{1}{\delta}\right) \right)$$

其中 δ 为错误概率, ε 为精度要求, H 是假设空间的大小.

Agnostic PAC: 在目标函数 $c^*(x) \notin H$

$$m = \frac{1}{2\varepsilon^2} \times \left(\log|H| + \log\left(\frac{2}{\delta}\right) \right)$$

shatter

给定点集合 ($X = \{x_1, \dots, x_m\}$), 如果:


对 **每一种** 标签到 ($\{+1, -1\}$) 的映射 ($Y = (y_1, \dots, y_m)$), 都存在一个模型参数 (w) 使得:

$$f(x_i; w) = y_i \quad \text{for all } i$$

则称模型 **shatter** 这个点集。

相当于是画出一个点集 X , 然后将 $2^{|X|}$ 中 Y 的情况全部画出来, 查看这个模型能否将这些点完全分开。

例如 $f(x) = \text{sign}(w^T x)$, $x \in \mathbb{R}^2$, 考虑 w 为两个正或两个负, 可以区分两个点的所有情况. 所以说其 shatter 两个点, 不能 shatter 三个点(最右边图中就不行).



shatter 的几个例子


圆分类器:

$$f(x) = \text{sign}(x^T x - b)$$

无法区分右侧的样本,因为在这种情况下外侧一定是正样本

$$f(x) = \text{sign}(qx^T x - b)$$

可以区分,因为在这种情况下内外侧可以是正或负样本.



VC 维

VC 维:最大的可以 shatter 的数据(只要存在一种排布就可以)的数量.

二维线性分类器($y = w^T x + b$)可以分开不共线的三个样本点,但是不能分开共线的三个样本点,它的 VC 维仍然是 3,因为只要求存在一种排布.

线性分类器结论

$$y = w^T x + b$$

$x \in \mathbb{R}^n$,最多可以 shatter 不共线的 $n+1$ 个样本,其 VC 维度为 $n + 1$.

圆分类器结论

$$f(x) = \text{sign}(qx^T x - b)$$

, $x \in \mathbb{R}^n, q \neq 0$,VC 维度为 1.

有效假设数量

我们希望衡量一个假设空间 H 的容量,也就是能够有多少分类方式.

如果直接数有多少 H 是不现实的,因为 H 可能有无限个假设.但是 H 所有的假设划分数据集 S 的划分数目是有限的,不少于全部划分数目 $2^{|S|}$.

记 $H[S]$ 表示 H 中所有假设可以对 S 所有划分结果的集合,

$H[m]$ 是 H 中所有假设可以对大小为 m 的 S 所有划分结果的划分情况最大数量.

$$H[m] = \max_{|S|=m} H[S]$$


对 $H[m]$ 理解为不同的 S 被 H 划分有不同的划分结果数目,但是有一种 S 可以有最多的划分结果个数.

$$H[m] \leq 2^{|S|}$$

因为最多的划分情况就是发生 shatter.


关于 $H[m]$ 的例子

线性阈值分类器的 $H[m]$



红色线是是线性阈值分类器,小于其为负样本,大于其为正样本,上图为一种划分方式. 那么由于 m 个数据有 $m + 1$ 个间隔,所以 $H[m] = m + 1$

区间分类器



区间内为正样本,区间外为负样本,选取区间端点 $\binom{m+1}{2} + 1$,加一是考虑到同一个间隔都表示全部样本为负样本,是同一种情况.

增长函数

$$G_H(m) = H[m]$$

表示在大小为 m 的数据集上有假设 H 最多有多少划分结果.最重要的在于 $G_H(m)$ 是如何随着 m 变化的.


由此再次引入 VC 维度的概念.

假设存在 d ,使得 $G_m(H) = \begin{cases} 2^m & m \leq d \\ < 2^m & m > d \end{cases}$ 则 d 为 VC 维.

也就是最大的可以 shatter 的数据(只要存在一种排布就可以)的数量.


VC 维的例子

线性阈值分类器的 $H[m]$



只能区分一个点,上图这种两个点的情况是无法区分的,因为小于阈值一定是负样本,所以 $\text{VCdim}(H) = 1$

区间分类器



无法区分上图情况,因为区间内必须是正样本,但是可以区分只有两个点的情况,所以 $\text{VCdim}(H) = 2$

VC 维的例子

结论 k 个区间分类器的并集的 $\text{VCdim} = 2k$ 在 $2k$ 的时候只需要在每一个正样本外面加一个区间,如果区间有多余就取空就可以了.

在 $2k + 1$ 的时候从正样本开始交替正负样本,这种情况下 $k + 1$ 一个互不相连的正样本,需要 $k + 1$ 个区间,但是只有 k 个,所以不能 shatter.

所以找 VCdim 关键在构建最难 shatter 的数据分布情况,并说明无法 shatter 这种情况.

无限 H 情况下的 PAC

可以学习要求

$$m = O\left(\frac{1}{\varepsilon} \left(\log \frac{1}{\delta} + \text{VCdim}(H)\right)\right)$$

如果保证假设类 H 中的所有假设的真实误差与经验误差之差都不超过 ε 。

$$m = O\left(\frac{1}{\varepsilon^2} \left(\log \frac{1}{\delta} + \text{VCdim}(H)\right)\right)$$

注意此处是 ε^2 和 $\text{VCdim}(H)$ (不是 $|H|$)

这说明可学习与 VC 维度有关,与假设空间中有多少假设关系不大.

SRM(Structural Risk Minimization)


$$\text{err}_D(h) < \text{err}_S(h) + \sqrt{\frac{\text{VCdim}(H) \log m + \log\left(\frac{1}{\delta}\right)}{m}}$$

从简单到复杂,排序样本空间 $H_1 < H_2 < \dots < H_k$,从 H_1 开始选择

然后训练,即 $\hat{h}_k = \text{argmin}_{h \in H_k} \text{err}_S(h)$

选取 $\hat{k} = \text{argmin}_{k \geq 1} \left(\text{err}_S(h) + \sqrt{\frac{\text{VCdim}(H_k)}{m}} \right)$

这样可以防止过拟合,因为 $\text{err}_S(h)$ 小,往往容易因为模型过于复杂而过拟合,所以使用 $\sqrt{\frac{\text{VCdim}(H_k)}{m}}$ 来表示模型复杂度,从而选取复杂度和训练误差都较优的.



图模型

贝叶斯网络

问题:表示联合分布需要很多的状态数目,比如保存 n 个 $\{0,1\}$ 取值的变量的联合需要计算 $2^n - 1$ 个概率(最后一个通过概率和为 1 计算),所以几乎是不可能的.

key idea: 引入条件独立关系简化计算. 有向无环图建模,用有向边表示 因果 或 条件依赖. 一个节点的概率只与其父节点有关,与其他节点独立.


因子分解 factorization

$$P(X_1, X_2, \dots, X_n) = \prod_{i=1}^n P(X_i \mid \text{Parents}(X_i))$$

Note

Chain rule 和 factorization 不相同

- Chain rule 始终成立，是对任意联合分布的机械展开。
- Factorization 是在链式法则基础上结合图结构（条件独立性）进行化简。



Chain Rule : $P(A, B, C, D, E, F, G)$
 $= P(A)P(B|A)P(C|A, B)P(D|A, B, C) \dots P(G|F, E, D, C, B, A)$

Factorization : $P(A, B, C, D, E, F, G)$
 $= P(G)P(F|G)P(D)P(A|D)P(E|A)P(B|E)P(C|D, B)$

假如二元,原来要 $2^7 - 1$ 个概率,现在只要 $1 + 2 + 1 + 2 + 2 + 2 + 4 = 14$ 个概率

构造贝叶斯网络

chain rule:

$$P(X_1, X_2, \dots, X_n) = \prod_{i=1}^n P(X_i \mid X_1, X_2, \dots, X_{i-1})$$

factorization:

$$P(X_1, X_2, \dots, X_n) = \prod_{i=1}^n P(X_i \mid \text{Parents}(X_i))$$

所以我们通过**构造**使得二者相等.

给定序列 $(X_1, X_2, \dots, X_n)$, 第一个 X_1 没有父亲, 从第二个开始从 $(X_1, X_2, \dots, X_{i-1})$ 选取最小集合使得

$$P(X_i \mid X_1, X_2, \dots, X_{i-1}) = P(X_i \mid \text{Parents}(X_i))$$

假设 $\text{Parents}(X_i)$ 开始的时候为 $\emptyset$, 如果在已有 $\text{Parents}(X_i)$ 条件下, $(X_1, X_2, \dots, X_{i-1})$ 中的 X_j 与 X_i 不独立(专家判断或者统计检验), 则加入 $\text{Parents}(X_i)$

如果 不假设任何独立性, 父节点就是全部前面变量.

贝叶斯网络学习

1. 图已知,所有数据已观测

使用 MLE 估计

$$P(X|\text{Parents}(X_i) = c_1, c_2, \dots) = \frac{N_{x, c_1, c_2, \dots}}{N_{c_1, c_2, \dots}}$$

2. 图已知,部分数据已观测

这个时候无法使用 MLE,使用 EM 算法估计 假设 Z 是部分观测的变量, X 是可观测量

$$\operatorname{argmax}_{\theta} E_{Z|X, \theta}(\log P_{Z, X|\theta})$$

3. 图未知,部分数据已观测

推理贝叶斯网络

假如只有 $\{A, B, C, D\}$ 4 个变量

Factorization 结果为 $P(A)P(B)P(C|A, B)P(D|A, B, C)$

计算整个联合分布 $P(A = a_0, B = b_0, C = c_0, D = d_0)$, 那么使用 Factorization 的结果计算查找条件分布表代入计算

计算部分条件联合分布




$$\begin{aligned} P(A = a_0, B = b_0) &= \sum_C \sum_D P(A)P(B)P(C|A, B)P(D|A, B, C) \\ &= P(A)P(B) \sum_C \sum_D P(C|A, B)P(D|A, B, C) \end{aligned}$$

计算条件概率 $P(A = a_0, B = b_0 \mid C = c_0, D = d_0) = \frac{P(A=a_0, B=b_0, C=c_0, D=d_0)}{P(C=c_0, D=d_0)}$

贝叶斯网络给出了一种简单的联合概率计算方法, 推理就可以使用其他概率运算法则去计算, 一个 trick 是利用 $\sum$ 算符性质提出无关项可以简化运算.

D-separated

problem: 在一个贝叶斯网络里, 询问两个变量在给定一些条件后是否独立

	Chain: 在观测到 B 后,A,C 就是独立的.
	Fork:在观测到 B 后,A,C 就是独立的.
	Collider:在观测到 B 或它的后代后,A,C 是相关的.

如果要判断两个节点之间的是否独立,只需要把路径分成多个三元组判断即可.


马尔可夫毯

马尔可夫毯是一个变量在网络中所有与它相关的“必要信息”的最小集合。

一个节点 X 的马尔可夫毯是由三类节点组成

1. 直接影响 X 的节点。
2. 受 X 影响的节点。
3. 与 X 共同影响某个子节点的其他节点。

$$\text{Markov Blanket}(X) = \text{Parents}(X) \cup \text{Children}(X) \cup \text{Co-parents}(X)$$




其中, B 的马尔可夫毯为 $\{A, C, D, F\}$

时间序列和马尔可夫模型


假设全部独立,则没有序列性

$$P(X_1, X_2, X_3, \dots, X_n) = P(X_1)P(X_2)P(X_3) \dots P(X_n)$$



直接计算联合分布,计算复杂度极高


$$P(X_1, X_2, X_3, \dots, X_n) = P(X_1)P(X_2|X_1)P(X_3 | X_1, X_2) \dots P(X_n | X_1, X_2, X_3, \dots, X_{n-1})$$



马尔可夫模型假设只与前面最近发生的事件有关


$$P(X_n | X_1, X_2, X_3, \dots, X_{n-1}) = P(X_n | X_{n-1})$$

$$P(X_1, X_2, X_3, \dots, X_n) = P(X_1)P(X_2|X_1)P(X_3 | X_2) \dots P(X_n | X_{n-1})$$



状态空间模型

我们很多时候只能观测到 Y_i ,但是系统有自己的状态 X_i (无法直接观测).



$$\begin{aligned} &P(X_1, X_2, \dots, X_n, Y_1, Y_2, \dots, Y_n) \\ &= P(X_1)P(Y_1|X_1)P(X_2|X_1)P(Y_2|X_2)\dots P(X_n|X_{n-1})P(Y_n|X_n) \end{aligned}$$

不一定是链状,也可能是树结构或者森林结构等结构.

集成学习

adaboost

adaboost 训练 T 个弱分类器及其权重,此处 $y = \{+1, -1\}$

算法流程如下:

1. 训练一个弱分类器 f_t
2. 使用弱分类器预测的结果和当前样本权重计算加权错误率

$$\varepsilon_t = \sum_{i=1}^m w_i * I(\hat{y}_i \neq y_i)$$

3. 通过加权错误率计算模型的权重

$$\alpha_t = \frac{1}{2} \log \left(\frac{1 - \varepsilon_t}{\varepsilon_t} \right)$$

4. 重新计算样本权重(衰减正确样本权重,提升错误样本权重)

$$w_i = w_i * \exp(-\alpha_t * y_i * \hat{y}_i)$$

5. 重复 1-4

6. 预测 $H(x) = \text{sign} \left(\sum_{t=1}^T \alpha_t * f_t(x) \right)$

kmeans

kmeans 算法

$\mu^{(i)}$ 表示数据 $x^{(i)}$ 属于的聚类中心, $\mu^{(i)} \in \{c_0, c_1, c_2, \dots, c_k\}$.

我们的目标是分成 k 个簇, 并最小化 loss 函数(误差平方和).

$$\text{minimize SSE} = \sum_{i=1}^n \|x^{(i)} - \mu^{(i)}\|^2$$

1. 随机生成 k 个中心点 $c_0, c_1, c_2, \dots, c_k$.

2-3 相当于固定中心点, 更新样本点的归属

2. 计算每个样本点到各个中心点的距离.
3. 将样本点分配到距离最近的中心点.

4 相当于固定样本点的归属, 更新中心点的位置

4. 重新计算各个中心点的位置.

5 迭代寻找局部最优解

5. 重复步骤 2-4, 直到中心点不再改变位置.

在这两步中, J 是不升的, 所以最终会收敛到一个局部最优解.

参数 k 和起始中心点的选择

起始中心点的选择

起始点的位置对于最后聚类的结果有一定的影响,常见的方案是随机多次并运行多次 kmeans,选取最小 loss 代表的最终聚类方案.


参数 k

随着 k 变大,SSE 单调递减,但是当 k 越大,递减越慢,但是边际效应越来越小,合适的 k^* 应当是在随着 k 变大时变化显著变小的那个点,

$k > k^*$: 继续增加类只是在将已有簇再切分成更小的子簇

$k < k^*$: 每增加一个类, 会显著减少 SSE (因为明显的分类结构被更好地划分)

给个例子,可视化如下,肘部为 $k = 3$ 的时候



异常检测

高斯异常检测

问题:大量正常数据,少量离群数据,如何检测.

假设数据每一个特征都服从独立的高斯分布,那么

$$P(x^{(i)}) = \prod_k P(x_k^{(i)}) = \prod_k \frac{1}{\sqrt{2\pi}\sigma_k} \exp\left(-\frac{(x_k^{(i)} - \mu_k)^2}{2\sigma_k^2}\right) < \varepsilon$$

我们认为检测异常, ε 人为设定.

选取特征的时候,如果特征左偏的话,可以取一个 $\log$.

训练的时候使用正常数据,交叉验证的时候使用正常数据+离群数据.我们要拟合的是正常数据的分布

联合高斯分布

特征之间是存在关系的所以之前的独立假设不咋合理.

使用联合高斯分布

$$\frac{1}{(2\pi)^{\frac{n}{2}} |\Sigma|^{\frac{1}{2}}} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1} (x - \mu)\right)$$

其中 μ 控制中心位置, Σ 控制对概率密度的敏感度.

使用多元高斯分布,要求满足 $m > n$,否则 Σ 不可逆

计算成本较高.

SVM

目标

我们考虑一个二分类,标签 $y \in \{-1, 1\}$

如果一个超平面的方程为 $w^T x + b = 0$ 那么样本 $x^{(i)}$ 到超平面的函数距离为

$$y^{(i)}(w^T x^{(i)} + b)$$

其几何距离为

$$\frac{y^{(i)}(w^T x^{(i)} + b)}{\|w\|}$$

支持向量机的目标是寻找一个超平面,这个超平面能尽可能分离正负样本,并且使得距离超平面最近的点(支持向量)到超平面的距离最大化.

考虑超平面方程改变若干倍还是对应同一个平面,最大化几何距离可以令 $(y^{(i)}(w^T x^{(i)} + b)) = 1$

相当于最小化 $\frac{1}{2}\|w\|^2$

约束条件为 $y^{(i)}(w^T x^{(i)} + b) \geq 1$

损失函数和梯度下降

完全可分,hard margin

$$\frac{1}{2}\|w\|^2$$

模糊可分,soft margin

$$\frac{1}{2}\|w\|^2 + C \sum_{i=1}^n \max(0, 1 - y^{(i)}(w^T x^{(i)} + b))$$

其中 $\max(0, 1 - y^{(i)}\hat{y}^{(i)})$ 被称为 hinge loss.

其本质上是引入了松弛 $y^{(i)}(w^T x^{(i)} + b) \geq 1 - \xi_i, \xi_i > 0$

最小化 $\frac{1}{2}\|w\|^2$ 的目的是为了最大化 margin, hinge loss 的目的是为了惩罚分类错误或者 margin 过小的数据,所以在梯度下降的时候只有在其小于 1 的时候才会更新梯度.

其中 C 越大,就会导致 varince,对于数据敏感,C 越小,就会导致 bias,在意的是间隔大,w 小.

预测

预测使用

$$\text{sign}(w^T x + b)$$

如果符号为正,则在超平面上方为正类,否则在超平面下方为负类,在超平面上的情况很少.么.

信心表示为

$$\frac{w^T x + b}{\|w\|}$$

即到决策超平面的距离.

核方法

核方法

problem: 有一些方法算到最后表达式中只有 $x^T x'$ 项,如果使用非线性变换 $\phi(x)$ 变换到高维度空间会造成带来较大时间成本.

method: 核函数

$$K(x, x') = \phi(x) \cdot \phi(x')$$

相当于是不用计算 $\phi(x)$ 和 $\phi(x')$,而是直接计算 $K(x, x')$.

例如原来需要映射 $\phi(x) = [x_1^2, \sqrt{2}x_1x_2, x_2^2]$, $\phi(x') = [x_1'^2, \sqrt{2}x_1'x_2', x_2'^2]$ 现在只需要 $K(x, x') = (x^T x')^2$,隐式的将特征映射到高维空间.

这样就不用计算高维映射,其计算复杂度和 x 的维度相关.

常见的核函数

1. 线性核

$$K(x, x') = x^T x', \text{相当于 } \phi(x) = x$$

2. 多项式核


$$K(x, x') = (x^T x' + c)^d, \text{自动生成各种高次特征}$$

3. 高斯核

$$K(x, x') = \exp\left(-\frac{\|x-x'\|^2}{2\sigma^2}\right)$$

核 svm

problem: 无法解决非线性问题,需要引入非线性变换



根据数学推导,svm 最后的函数表达式可以写作

$$f(x) = \sum (a_i y_i (x_i^T x)) + b$$

引入变换后


$$f(x) = \sum (a_i y_i K(x_i, x)) + b$$

引入高斯核函数,选取部分数据作为 landmark 地标,通过与地标做高斯核计算相似性做为新的特征 f_i .选取所有数据点都作为 landmark 比较合适.


关于高斯核参数

$$\text{高斯核 } K(x, x') = \exp\left(-\frac{\|x-x'\|^2}{2\sigma^2}\right)$$

如果参数 σ 过大,变化慢 $\rightarrow$ 决策边界非常光滑,则 bias



如果参数 σ 过小,变化快 $\rightarrow$ 边界变得非常曲折,则 virance



一般在样本密集的时候, σ 应该选择较小.在样本稀疏的数据中, σ 应该选择较大.

神经网络

前向传播

$$z^{(1)} = W^{(1)}x + b^{(1)}$$

$$a^{(1)} = f(z^{(1)})$$

$$z^{(2)} = W^{(2)}a^{(1)} + b^{(2)}$$

$$a^{(2)} = f(z^{(2)})$$

...

$$z^{(L)} = W^{(L)}a^{(L-1)} + b^{(L)}$$

$$a^{(L)} = f(z^{(L)})$$

...

$$a^{(R-1)} = f(z^{(R-1)})$$

$$a^{(R)} = z^{(R)} = W^{(R)}a^{(R-1)} + b^{(R)}$$

$$L = \frac{1}{2}(a^{(R)} - y)^2$$

损失函数

如果是分类任务的话,最后一层过一个 softmax,然后使用交叉熵损失函数

$$L = - \sum_{i=1}^m y^i \log(\hat{y}^i)$$

如果是回归任务的话,最后一层不经过激活函数,直接输出,然后使用均方误差损失函数

$$L = \frac{1}{2} \sum_{i=1}^m (y^i - a^i)^2$$

同时,可以增加一个正则项,如 L2 正则化,使得模型更简单,防止过拟合

反向传播

假设 $\delta^{(i)} = \frac{\partial L}{\partial z^{(i)}}$

那么根据链式求导法则

$$\frac{\partial L}{\partial W^{(i)}} = \frac{\partial L}{\partial z^{(i)}} * \frac{\partial z^{(i)}}{\partial W^{(i)}} = \delta^{(i)} * a^{(i-1)}$$

$$\frac{\partial L}{\partial b^{(i)}} = \frac{\partial L}{\partial z^{(i)}} * \frac{\partial z^{(i)}}{\partial b^{(i)}} = \delta^{(i)}$$

关键在于计算 $\delta^{(i)}$, 方法为通过递推

$$\begin{aligned} \frac{\partial L}{\partial z^{(i)}} &= \frac{\partial L}{\partial a^{(i)}} \odot f'(z^{(i)}) = \frac{\partial L}{\partial z^{(i+1)}} \frac{\partial z^{(i+1)}}{\partial a^{(i)}} \odot f'(z^{(i)}) \\ &= (W^{(i+1)})^T \delta^{(i+1)} \odot f'(z^{(i)}) \end{aligned}$$

训练过程小批量随机梯度下降, 每次先前向传播计算损失, 然后反向传播计算梯度, 再使用梯度下降更新参数.

实现技巧

通过

$$\frac{f(z + \varepsilon) - f(z - \varepsilon)}{2 \times \varepsilon}$$

可以手动计算梯度,查看梯度是否发生爆炸或者变成 0

初始化 θ 时候要随机初始化,目的是为了打破对称性.如果全是 0,那么梯度和预测值都是一样的,所有神经元完全同步 (同步更新、同步输出),没有任何差异性.所以初始化的时候要随机.

online learning

online learning

problem: 训练数据标注成本高,是否可以不通过标注所有样本,而是标注部分样本来训练模型?

method:

Batch Active Learning: 每次想专家询问一批数据的结果,而不是一次性标注所有数据,这样就可以选择一些批不标注

Selective Sampling Active Learning: 数据流式到达,每到达一个样本就决定是否标注.如果决定要标注,就请专家标注.

online svm

选择最接近当前样本子集下训练出的 SVM 决策边界的未标注样本标注, 即选择 $\| w^T x + b \|$ 最小进行标注, 然后重新训练 SVM, 重复上述过程, 直到标签预算用完, 模型收敛, 性能达到要求.

半监督学习

概念

有监督学习	无监督学习	半监督学习
所有数据已经标注	没有数据已经标注	少量数据已经标注,大部分没有标注

co-training

假设有两个特征 x_1 和 x_2 ,假设这两个特征都可以将数据完全分离,且基于这两个特征对于数据最终的分类结果一致.

那么我们训练两个分类器,分别基于一个特征分类,设为 h_1 和 h_2 ,循环下面步骤,

选取一个自信,但是另外一个不自信的样本,用自信的那个标注后用于训练不自信的那个.

目标函数如下

$$\operatorname{argmin}_{h_1, h_2} = \sum_{i=1}^{m_l} l(h_1(x_i), y_i) + \sum_{i=1}^{m_l} l(h_2(x_i), y_i) + C \sum_{i=1}^{m_u} \text{agreement}(h_1(x_i), h_2(x_i))$$

前面两项是要求两个分类器可以分开有标记数据,最后一项数据要求两种分类器在同一个无标签数据上预测结果尽量一致(**agreement**).

推荐系统

问题和目标

我们已知 $r(i, j)$ 表示用户是否对于商品 i 的 j 属性打分(很有可能大量未打分数据), $y(i, j)$ 表示用户对于商品 i 的 j 属性打分的数值.

我们通过用户偏好向量 $\theta^{(i)}$ 来刻画用户的偏好,使用物品特征向量 $x^{(k)}$ 表示一个物品的特征

通过 $\theta^{(i,j)} \times x^{(k,j)}$ 来预测最后用户 i 对于物品 k 的 j 属性的打分

$\sum_j \theta^{(i,j)} \times x^{(k,j)}$ 来预测最后用户 i 对于物品 k 的总分,即 $y(i, j)$

已知内容的推荐系统

已经知道 $x^{(k)}$ 目标是训练 $\theta^{(i)}$ 那么训练的目标函数是

$$\min_{\theta} \frac{1}{2} \sum_{i,k,r(i,k)=1} \left((\theta^{(i)})^T x^{(k)} - y(i,k) \right)^2 + \frac{\lambda}{2} \sum_i \sum_j (\theta^{(i,j)})^2$$

前面最小化 mse,后面 L2 正则化

协同过滤算法

不知道 $x^{(k)}$ 和 $\theta^{(i)}$

两步优化是第一步固定 $x^{(k)}$ 优化 $\theta^{(i)}$,第二步固定 $\theta^{(i)}$ 优化 $x^{(k)}$

第一步优化 $\theta^{(i)}$

$$\min_{\theta} \frac{1}{2} \sum_{i,k,r(i,k)=1} \left((\theta^{(i)})^T x^{(k)} - y(i,k) \right)^2 + \frac{\lambda}{2} \sum_i \sum_j (\theta^{(i,j)})^2$$

第二步优化 $x^{(k)}$

$$\min_x \frac{1}{2} \sum_{i,k,r(i,k)=1} \left((\theta^{(i)})^T x^{(k)} - y(i,k) \right)^2 + \frac{\lambda}{2} \sum_k \sum_j (x^{(k,j)})^2$$

不停重复, 优化 $\theta \rightarrow x \rightarrow \theta \rightarrow x \rightarrow \theta \rightarrow \dots$,最终收敛到一组参数.

实际上合为一个,也可以优化,直接梯度下降

$$\min_{\theta,x} \frac{1}{2} \sum_{i,k,r(i,k)=1} \left((\theta^{(i)})^T x^{(k)} - y(i,k) \right)^2 + \frac{\lambda}{2} \sum_i \sum_j (\theta^{(i,j)})^2 + \frac{\lambda}{2} \sum_k \sum_j (x^{(k,j)})^2$$

低秩矩阵分解

评分举证 Y 这个矩阵有很多空缺,所以其 rank 不高

将其分解成为两个矩阵

$$Y = \Theta X^T$$

其中 $X \in R^{m \times k}$, $\Theta \in R^{n \times k}$, k 小于 m 和 n ,前者是物品特征因子,后者是用户偏好因子

一个低秩矩阵意味着:

这个矩阵中所有列 (行) 都可以由少数基向量线性组合得出。

⇒ 用户行为背后只有少数几个驱动力 (latent factors)

作用: 可以防止过拟合

寻找相似电影

使用

$$\|x^{(i)} - x^{(j)}\|$$

越小越相似

均值归一化

problem: 可能全局高分但是用户不喜欢,其关键在于相对于平均分的偏离大小,而不是分数本身的大小.毕竟有可能高分电影导致即使 θ 小,都会被推荐.

训练时候

$$y'^{(i,j)} = y^{(i,j)} - \mu_i$$

预测时候

$$\widehat{y^{(i,j)}} = \widehat{y'^{(i,j)}} + \mu_i$$

预测的是相对于均值的偏离量,这样预测出来的 θ 才是可以减少全局趋势影响,更加贴近用户偏好.另外如果是一个什么评分都没有的用户应该考虑使用平均分.

训练数据

大量数据和人工合成

模型参数量大,特征数多,往往需要更多的训练数据,否则容易过拟合.

当数据的特征能够提供足够的信息来预测的时候,数据量增多才是有效的.

添加人工合成的噪声的时候需要让其尽量在真实世界存在,随机噪声意义并不是很大.

调试机器学习


评估模型

分成

1. 训练集:用于训练模型参数
2. 验证集:用于在训练过程中评估模型,用于选择模型,训练者可能知道答案
3. 测试集:用于把模型放入到生产环境,最后一次评估泛化效果, 不能提前用,训练者不知道答案.

high bias: 指的是欠拟合,模型过于简单,这时候验证集上和训练的准确率都低


high variance: 模型过于复杂,过拟合,这时候训练集上的准确度高,验证集上准确度低




模型调试

goal: 我们要选择一个合适复杂度的模型拟合数据

正则项系数 λ 和模型的关系




特征数量 d 和模型的关系



模型调试

训练集大小 m 和模型的关系:上图欠拟合,需要更多数据,下图过拟合,需要更少数据.



还可以使用增加多项式特征,来防止 bias,但是容易 variance.

评估指标

TP,FP,FN,TN,Precision,Recall,F1

	预测 Positive	预测 Negative
真实 Positive	TP	FN(第二类错误)
真实 Negative	FP(第一类错误)	TN

可以认为命名规则是 正/误+预测结果

Precision 指的是所有预测为真的值中有几个是正确的,评估的是预测 1 的正确性

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

Recall 指的是所有实际为真的值中有几个是正确的,评估的是预测 1 时漏掉的可能性(负相关)

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

F1-Score

对于一个逻辑回归模型,假如目前阈值是 0.5,那么

提升 Precision 意味着提升阈值(更加不容易预测为正,容易漏检)

提升 Recall 意味着降低阈值(更加容易预测为正,容易误报)

F1-Score 是二者的调和平均

$$F1 = 2 \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

选用调和平均是因为其对于大 Precision 且大 Recall 值都才大,而算数平均在某一项就较大的时候值也较大.